PRÁCTICA DE CLASE

Podemos arrancar Hive con docker utilizando dos formas distintas. Una es con un cluster montado con varias imágenes y otra con la imagen oficial de Hive.

Segunda forma:

Descargar el comprimido: https://profesorfp.es/Big-Data-Cluster-main.zip

Abrir la carpeta con Visual Studio Code

En el fichero **`hive-sqoop-postgres-cassandra-docker-compose.yaml`** podéis comentar los siguientes servicios que de momento no vamos a usar:

- huedb
- hue
- external_postgres_db
- external_pgadmin
- cassandra

Ejecutar en la consola:

```
docker-compose -f hive-sqoop-postgres-cassandra-docker-compose.yaml
up -d
docker exec -it hive-server bash
```

Primeras Prácticas HIVE:

Los comandos con fondo verde se ejecutan en la consola de linux y los de fondo azul en la consola de Hive

- Hacemos un primer intento de conectarnos. Si nos conectamos usando beeline sin cadena de conexión no estamos conectando de verdad.

```
beeline
```

```
show databases;          → vemos que no hay conexión
!quit
!q
```

```
root@ba4628e68d26:/# beeline
SLF4J: Class path contains multiple SLF4J bindings.
SLF4J: Found binding in [jar:file:/opt/hive/lib/log4j-slf4j
SLF4J: Found binding in [jar:file:/opt/hadoop-2.7.4/share/h
SLF4J: See http://www.slf4j.org/codes.html#multiple_binding
SLF4J: Actual binding is of type [org.apache.logging.slf4j.
Beeline version 2.3.2 by Apache Hive
beeline> show databases;
No current connection
beeline> !quit
root@ba4628e68d26:/#
```

- Si ahora nos conectamos usando beeline con cadena de conexión y hacemos el show databases; ya sí que obtendremos información.

```
beeline -u 'jdbc:hive2://localhost:10000/'
```

```
show databases;
```

```
PROBLEMS    OUTPUT    DEBUG CONSOLE    TERMINAL    PORTS    POLYGLOT NOTEBOOK

root@ba4628e68d26:/# beeline -u 'jdbc:hive2://localhost:10000/'
SLF4J: Class path contains multiple SLF4J bindings.
SLF4J: Found binding in [jar:file:/opt/hive/lib/log4j-slf4j-impl-2.6.2.jar!/org/slf4j/
SLF4J: Found binding in [jar:file:/opt/hadoop-2.7.4/share/hadoop/common/lib/slf4j-log
SLF4J: See http://www.slf4j.org/codes.html#multiple_bindings for an explanation.
SLF4J: Actual binding is of type [org.apache.logging.slf4j.Log4jLoggerFactory]
Connecting to jdbc:hive2://localhost:10000/
Connected to: Apache Hive (version 2.3.2)
Driver: Hive JDBC (version 2.3.2)
Transaction isolation: TRANSACTION_REPEATABLE_READ
Beeline version 2.3.2 by Apache Hive
0: jdbc:hive2://localhost:10000/> show databases;
+----------------+
| database_name  |
+----------------+
| default        |
+----------------+
1 row selected (0.811 seconds)
0: jdbc:hive2://localhost:10000/>
```

- Vamos a listar el directorio del datawarehouse. Vemos que está vacío:

```
hdfs dfs -ls /user/hive/warehouse/
```

Pon captura de pantalla del comando y el resultado:

No hay salida porque está vacio **

- Si listara por ejemplo /user si que habría salida.

```
root@ba4628e68d26:/# hdfs dfs -ls /user
Found 1 items
drwxr-xr-x   - root supergroup          0 2026-02-11 15:50 /user/hive
root@ba4628e68d26:/# hdfs dfs -ls /user/hive/warehouse/
root@ba4628e68d26:/#
```

- Creamos una base de datos

```
create database prueba_clase;
show databases;
```

Pon captura de pantalla del comando y el resultado:

```
+----------------+
| database_name  |
+----------------+
| default        |
| prueba_clase   |
+----------------+
2 rows selected (0.055 seconds)
```

```
0: jdbc:hive2://localhost:10000/> create database prueba_clase;
No rows affected (0.879 seconds)
0: jdbc:hive2://localhost:10000/> show databases;
+----------------+
| database_name  |
+----------------+
| default        |
| prueba_clase   |
+----------------+
2 rows selected (0.055 seconds)
0: jdbc:hive2://localhost:10000/>
```

- Creamos una tabla en ella

```
use prueba_clase;
create table test1(uno int);
show tables;
```

Pon captura de pantalla del comando y el resultado:

```
+-----------+
| tab_name  |
+-----------+
| test1     |
+-----------+
```

```
2 rows selected (0.055 seconds)
0: jdbc:hive2://localhost:10000/> use prueba_clase;
No rows affected (0.06 seconds)
0: jdbc:hive2://localhost:10000/> create table test1(uno int);
No rows affected (0.379 seconds)
0: jdbc:hive2://localhost:10000/> show tables;
+-----------+
| tab_name  |
+-----------+
| test1     |
+-----------+
1 row selected (0.047 seconds)
0: jdbc:hive2://localhost:10000/>
```

- EN LINUX - Vamos a listar el directorio del datawarehouse

```
hdfs dfs -ls /user/hive/warehouse/
```

Pon capturas de pantalla:

```
root@ba4628e68d26:/# hdfs dfs -ls /user/hive/warehouse/
Found 1 items
drwxrwxr-x   - root supergroup          0 2026-02-25 14:41 /user/hive/warehouse/prueba_clase.db
root@ba4628e68d26:/#
```

```
hdfs dfs -ls /user/hive/warehouse/prueba_clase.db
```

Pon capturas de pantalla:

```
root@ba4628e68d26:/# hdfs dfs -ls /user/hive/warehouse/prueba_clase.db
Found 1 items
drwxrwxr-x   - root supergroup          0 2026-02-25 14:41 /user/hive/warehouse/prueba_clase.db/test1
root@ba4628e68d26:/#
```

```
hdfs dfs -ls /user/hive/warehouse/prueba_clase.db/test1
```

Pon capturas de pantalla:

```
root@ba4628e68d26:/# hdfs dfs -ls /user/hive/warehouse/prueba_clase.db/test1
root@ba4628e68d26:/#
```

No hay datos

- Insertamos datos

```
insert into test1 values (10);
select * from test1;
```

Pon captura de pantalla:

```
1 row selected (0.047 seconds)
0: jdbc:hive2://localhost:10000/> insert into test1 values (10);
WARNING: Hive-on-MR is deprecated in Hive 2 and may not be available in the futu
k, tez) or using Hive 1.X releases.
No rows affected (18.983 seconds)
0: jdbc:hive2://localhost:10000/> select * from test1;
+------------+
| test1.uno  |
+------------+
| 10         |
+------------+
1 row selected (0.181 seconds)
0: jdbc:hive2://localhost:10000/>
```

- Vamos a listar el directorio del datawarehouse

```
hdfs dfs -ls /user/hive/warehouse/prueba_clase.db/test1
hdfs dfs -cat
/user/hive/warehouse/prueba_clase.db/test1/000000_0
```

Pon captura de pantalla:

```
root@ba4628e68d26:/# hdfs dfs -ls /user/hive/warehouse/prueba_clase.db/test1
Found 1 items
-rwxrwxr-x   3 root supergroup          3 2026-02-25 14:46 /user/hive/warehouse/prueba_clase.db/test1/000000_0
root@ba4628e68d26:/# hdfs dfs -cat
-cat: Not enough arguments: expected 1 but got 0
Usage: hadoop fs [generic options] -cat [-ignoreCrc] <src> ...
root@ba4628e68d26:/# hdfs dfs -cat /user/hive/warehouse/prueba_clase.db/test1/000000_0
10
root@ba4628e68d26:/#
```

- Creamos una nueva tabla empleados.

```
create table empleados
(
      nombre string,
      edad int
)
row format delimited
fields terminated by ',';
```

```
0: jdbc:hive2://localhost:10000/> create table empleados
. . . . . . . . . . . . . . . . . > (
. . . . . . . . . . . . . . . . . > nombre string,
. . . . . . . . . . . . . . . . . > edad int
. . . . . . . . . . . . . . . . . > )
. . . . . . . . . . . . . . . . . > row format delimited
. . . . . . . . . . . . . . . . . > fields terminated by ',';
No rows affected (0.114 seconds)
0: jdbc:hive2://localhost:10000/>
```

- Creamos un fichero empleados.txt en linux con los datos:

```
cd
nano empleados.txt

Clara,23
Manuel,24
Miguel,34
Juan,20
Ana,18
```

```
  GNU nano 2.2.6                                  File: empleados.txt

Clara,23
Manuel,24
Miguel,34
Juan,20
Ana,18
```

- Lo vamos a cargar desde la consola de hive

```
load data local inpath '/root/empleados.txt' into table
empleados;
```

- Comprobamos que se han insertado

```
select * from empleados;
```

Pon captura de pantalla:

```
0: jdbc:hive2://localhost:10000/> load data local inpath '/root/empleados.txt' into table empleados;
No rows affected (0.774 seconds)
0: jdbc:hive2://localhost:10000/> select * from empleados;
+-------------------+-----------------+
| empleados.nombre  | empleados.edad  |
+-------------------+-----------------+
| Clara             | 23              |
| Manuel            | 24              |
| Miguel            | 34              |
| Juan              | 20              |
| Ana               | 18              |
|                   | NULL            |
+-------------------+-----------------+
6 rows selected (0.28 seconds)
0: jdbc:hive2://localhost:10000/>
```

- MIRAMOS EN /user/hive/warehouse/ en la herramienta y vemos que ha cargado directamente el fichero en el directorio.

```
hdfs dfs -cat
/user/hive/warehouse/prueba_clase.db/empleados/empleados.txt
```

Pon captura de pantalla:

```
root@ba4628e68d26:~# hdfs dfs -cat /user/hive/warehouse/prueba_clase.db/empleados/empleados.txt
Clara,23
Manuel,24
Miguel,34
Juan,20
Ana,18

root@ba4628e68d26:~#
```

- Subimos el fichero directamente al HDFS con un put, y a ver qué pasa.

```
hdfs dfs -put empleados.txt
/user/hive/warehouse/prueba_clase.db/empleados/empleados2.txt
```

- Comprobamos qué ha pasado en la tabla

```
select * from empleados;
```

Pon captura de pantalla:

```
0: jdbc:hive2://localhost:10000/> select * from empleados;
+-------------------+-----------------+
| empleados.nombre  | empleados.edad  |
+-------------------+-----------------+
| Clara             | 23              |
| Manuel            | 24              |
| Miguel            | 34              |
| Juan              | 20              |
| Ana               | 18              |
|                   | NULL            |
| Clara             | 23              |
| Manuel            | 24              |
| Miguel            | 34              |
| Juan              | 20              |
| Ana               | 18              |
|                   | NULL            |
+-------------------+-----------------+
12 rows selected (0.152 seconds)
0: jdbc:hive2://localhost:10000/>
```

- Vamos a mirar en el HDFS a ver si están los dos ficheros

```
hdfs dfs -ls /user/hive/warehouse/prueba_clase.db/empleados
```

Pon captura de pantalla:

```
root@ba4628e68d26:~# hdfs dfs -ls /user/hive/warehouse/prueba_clase.db/empleados
Found 2 items
-rwxrwxr-x   3 root supergroup         45 2026-02-25 14:50 /user/hive/warehouse/prueba_clase.db/e
-rw-r--r--   3 root supergroup         45 2026-02-25 14:51 /user/hive/warehouse/prueba_clase.db/e
root@ba4628e68d26:~#
```

- Vamos a borrar del HDFS uno de los ficheros

```
hdfs dfs -rm
/user/hive/warehouse/prueba_clase.db/empleados/empleados2.txt
```

- Comprobamos qué ha pasado en la tabla

```
select * from empleados;
```

Al borrar el fichero no me salen esos datos en la tabla

```
12 rows selected (0.152 seconds)
0: jdbc:hive2://localhost:10000/> select * from empleados;
+-------------------+-----------------+
| empleados.nombre  | empleados.edad  |
+-------------------+-----------------+
| Clara             | 23              |
| Manuel            | 24              |
| Miguel            | 34              |
| Juan              | 20              |
| Ana               | 18              |
|                   | NULL            |
+-------------------+-----------------+
6 rows selected (0.13 seconds)
0: jdbc:hive2://localhost:10000/>
```

- Si ahora borramos la tabla veremos que desaparecen del directorio.

```
drop table empleados;
```

- Después de hacer un drop de la tabla me ha borrado el directorio de la tabla.

```
hdfs dfs -ls /user/hive/warehouse/prueba_clase.db
```

Pon captura de pantalla:

```
root@ba4628e68d26:~# hdfs dfs -ls /user/hive/warehouse/prueba_clase.db
Found 2 items
drwxrwxr-x   - root supergroup          0 2026-02-25 14:52 /user/hive/warehouse/prueba_clase.db/empleados
drwxrwxr-x   - root supergroup          0 2026-02-25 14:46 /user/hive/warehouse/prueba_clase.db/test1
root@ba4628e68d26:~#
```

- TABLAS EXTERNAS. Vamos primero a crear un directorio donde almacenar los datos de las tablas externas.

```
hdfs dfs -mkdir /user/hive/datos
```

- Creamos una nueva tabla externa empleados-externa

```
create external table empleados_externa
(
nombre string,
edad integer
)
row format delimited
fields terminated by ','
location '/user/hive/datos/empleados';
```

Pon captura de pantalla:

```
0: jdbc:hive2://localhost:10000/> drop table empleados;
No rows affected (0.042 seconds)
0: jdbc:hive2://localhost:10000/> create external table empleados_externa
. . . . . . . . . . . . . . . . > (
. . . . . . . . . . . . . . . . > nombre string,
. . . . . . . . . . . . . . . . > edad integer
. . . . . . . . . . . . . . . . > )
. . . . . . . . . . . . . . . . > row format delimited
. . . . . . . . . . . . . . . . > fields terminated by ','
. . . . . . . . . . . . . . . . > location '/user/hive/datos/empleados';
No rows affected (0.113 seconds)
```

- Vamos a insertar datos

```
load data local inpath '/root/empleados.txt' into table
empleados_externa;
```

- Vamos a comprobar que el fichero está en su sitio.

```
hdfs dfs -ls /user/hive/datos/empleados
```

Pon captura de pantalla:

```
root@ba4628e68d26:~# hdfs dfs -ls /user/hive/datos/empleados
Found 1 items
-rwxr-xr-x   3 root supergroup         45 2026-02-25 14:55 /user/hive/datos/empleados/empleados.txt
root@ba4628e68d26:~#
```

- Si ahora borramos la tabla externa con un drop no deberían borrarse los datos.

```
drop table empleados_externa;
```

Pon captura de pantalla:

```
0: jdbc:hive2://localhost:10000/> drop table empleados_externa;
No rows affected (0.799 seconds)
0: jdbc:hive2://localhost:10000/>
```

- Comprobamos que el fichero no se ha borrado al hacer un drop de la tabla.

```
hdfs dfs -ls /user/hive/datos/empleados
```

Pon captura de pantalla:

```
root@ba4628e68d26:~# hdfs dfs -ls /user/hive/datos/empleados
Found 1 items
-rwxr-xr-x   3 root supergroup         45 2026-02-25 14:55 /user/hive/datos/empleados/empleados.txt
root@ba4628e68d26:~#
```

- Si volvemos a crear otra tabla externa en el mismo directorio y fichero en el que los datos ya estaban volverán a estar en la tabla

```
create external table empleados_externa2
(
nombre string,
edad integer
)
row format delimited
fields terminated by ','
location '/user/hive/datos/empleados';
```

- Vamos a hacer una consulta

```
select * from empleados_externa2 where edad>23;
```

Pon captura de pantalla:

```
0: jdbc:hive2://localhost:10000/> select * from empleados_externa2 where edad>23;
+---------------------------+-------------------------+
| empleados_externa2.nombre | empleados_externa2.edad |
+---------------------------+-------------------------+
| Manuel                    | 24                      |
| Miguel                    | 34                      |
+---------------------------+-------------------------+
2 rows selected (0.826 seconds)
0: jdbc:hive2://localhost:10000/>
```

- Vamos a extraer los datos de la consulta a un fichero de un directorio ubicado en linux.

```
INSERT OVERWRITE local directory '/root/consulta'
row format delimited
fields terminated by ','
select * from empleados_externa2 where edad>23;
```

- Si vamos a la ruta indicada en al comando anterior veremos que hay un fichero 000000_0 con el resultado de la consulta.

```
cd /root/consulta
ls
cat 000000_0
```
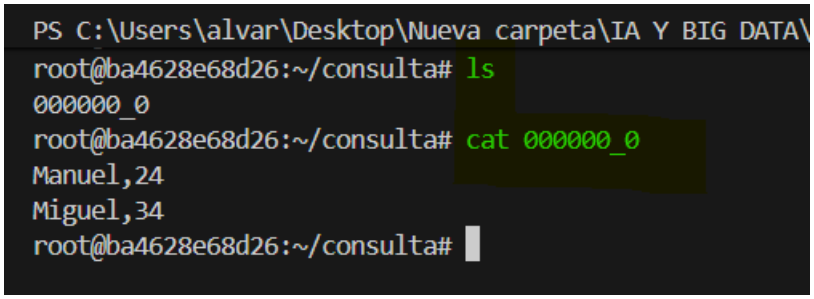
Pon captura de pantalla: