

✓ SAA - ACTIVIDAD 3.17 - ÁLVARO FERNÁNDEZ BECERRA

Entrena un clasificador basado en RandomForestClassifier de Scikit-Learn para el dataset de MNIST.


Realiza validación simple con un 80% de datos de entrenamiento y el resto para validación.

Obten la tasa de aciertos (accuracy score) para el dataset de validación y después intentar obtener la mejor tasa de aciertos posible utilizando distintos valores para los parámetros de RandomForestClassifier.

Utiliza para finalizar GridSearchCV, pero ten en cuenta que es un dataset muy grande y el entrenamiento tarda mucho, por lo que no es viable probar con demasiadas combinaciones.

```
from sklearn.datasets import fetch_openml
import random
import numpy as np
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import accuracy_score
from sklearn.model_selection import GridSearchCV

mnist = fetch_openml('mnist_784')
x = mnist.data
y = mnist.target
# Mostrar varios dígitos al azar
numdig=5
for i in range(0,numdig):
    ind = random.randint(0, x.shape[0])
    digit=x.iloc[ind]
    digit_pixels = np.array(digit).reshape(28, 28)
    plt.subplot(1, numdig, i+1)
    plt.imshow(digit_pixels, cmap="Greys")
    plt.title('%i\n (%s)' % (ind, y[ind]))
```



✓ Split

```
x_train, x_test, y_train, y_test = train_test_split(x, y, test_size=0.2, random_state=33)
```

✓ RandomForest

```
clf = RandomForestClassifier(random_state=33, n_jobs=-1)
clf.fit(x_train, y_train)

# Make predictions on the validation set
y_pred = clf.predict(x_test)

# Calculate the accuracy score
accuracy = accuracy_score(y_test, y_pred)
print(f"Accuracy inicial: {accuracy}")
```

Accuracy inicial: 0.9697142857142858

✓ GridSearch

```
param_grid = {
    #'criterion':      ['gini', 'entropy'],
    #'min_samples_split': [1, 2, 4, 8], # Por defecto: 2
    #'min_samples_leaf': [1, 2, 4, 8], # Por defecto: 1
    'max_depth':      [None, 4, 8],
    'n_estimators':    [100, 200, 300],
    'max_features':    [None, 'sqrt', 'log2']
```

```
}

#GridSearchCV
grid_clf = GridSearchCV(estimator = RandomForestClassifier(random_state = 33), param_grid = param_grid, cv = 5)

grid_clf.fit(x, y)

# Mejores parametros y score
best_params = grid_clf.best_params_
best_score = grid_clf.best_score_

print(f"Mejores params: {grid_clf.best_params_}")
print(f"Mejor Score: {grid_clf.best_score_}")

# Mejor modelo
mejor = grid_clf.best_estimator_
y_pred_2 = mejor.predict(x_test)
accuracy_2 = accuracy_score(y_test, y_pred_2)
print(f"Accuracy despues de GridSearch: {accuracy_2}")
```

- He intentado dejarlo ejecutando varias veces durante horas y no consigo que termine de ejecutarse.