SBD - Actividad 3.14 - Álvaro Fernández Becerra

Crea un clasificador basado en un árbol de decisión con DecisionTreeClassifier a partir del dataset disponible en http://archive.ics.uci.edu/dataset/109/wine para predecir el origen de los vinos basados en los resultados de análisis químicos.

Utiliza validación simple, con un 20% de datos para validación y el resto para entrenamiento.

- Muestra la matriz de confusión.
- Muestra gráficamente el árbol de decisión.
- Muestra en un grafico la relevancia de los atributos para el árbol de decisión generado.

```
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.preprocessing import LabelEncoder
from sklearn.tree import DecisionTreeClassifier, plot_tree
from sklearn.metrics import confusion_matrix, ConfusionMatrixDisplay, accuracy_score
from sklearn.model_selection import train_test_split

# Carga csv
columnas = [
    'class', 'alcohol', 'malic_acid', 'ash', 'alcalinity_of_ash', 'magnesium',
    'total_phenols', 'flavanoids', 'nonflavanoid_phenols', 'proanthocyanins',
    'color_intensity', 'hue', 'od280_od315', 'proline'
]

df = pd.read_csv('wine.data', header=None, names=columnas)
df.head()
```

	class	alcohol	malic_acid	ash	alcalinity_of_ash	magnesium	total_phenols	flavanoids	nonflavanoid_phenols	proanthocyanins	color_intensity	hue	od280_od3
0	1	14.23	1.71	2.43	15.6	127	2.80	3.06	0.28	2.29	5.64	1.04	3
1	1	13.20	1.78	2.14	11.2	100	2.65	2.76	0.26	1.28	4.38	1.05	3
2	1	13.16	2.36	2.67	18.6	101	2.80	3.24	0.30	2.81	5.68	1.03	3
3	1	14.37	1.95	2.50	16.8	113	3.85	3.49	0.24	2.18	7.80	0.86	3
4	1	13.24	2.59	2.87	21.0	118	2.80	2.69	0.39	1.82	4.32	1.04	2

Pasos siguientes: Generar código con df | New interactive sheet

```
for col in df.columns:
    df[col] = LabelEncoder().fit_transform(df[col])
```

```
df.columns
```

```
Index(['class', 'alcohol', 'malic_acid', 'ash', 'alcalinity_of_ash',
       'magnesium', 'total_phenols', 'flavanoids', 'nonflavanoid_phenols',
       'proanthocyanins', 'color_intensity', 'hue', 'od280_od315', 'proline'],
      dtype='object')
```

```
# x,y
x = df.drop('class', axis=1)
y = df['class']
```

Clasificador:

```
RANDOM_SEED = 42

x_train, x_test, y_train, y_test = train_test_split(
    x, y, test_size=0.2, random_state=RANDOM_SEED
)
```

```
clf = DecisionTreeClassifier(random_state=42)
clf.fit(x_train, y_train)
y_pred = clf.predict(x_test)

accuracy = accuracy_score(y_test, y_pred)
print(f"Accuracy en validación: {accuracy:.4f}")
```

```
Accuracy en validación: 0.9444
```

Matriz de confusion:

```
cm = confusion_matrix(y_test, y_pred)

disp = ConfusionMatrixDisplay(confusion_matrix=cm, display_labels=clf.classes_)
disp.plot(cmap='Blues')
plt.title('Matriz de confusión')
plt.show()
```

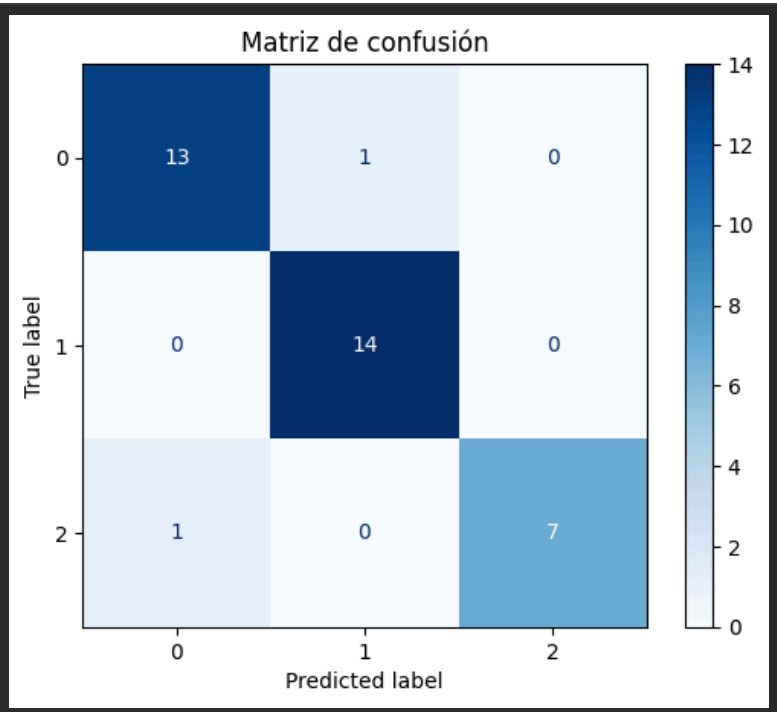

- Habria 2 observaciones clasificadas erroneamente

Arbol de decision:

```
plt.figure(figsize=(20, 10))
plot_tree(
    clf,
    feature_names=x.columns,
    class_names=[str(c) for c in clf.classes_],
    filled=True,
    rounded=True
)
plt.legend()
plt.show()
```

```
/tmp/ipykernel_11215/1761823887.py:9: UserWarning: No artists with labels found to put in legend.  Note that artists whose label start with an underscore are igno
  plt.legend()
```

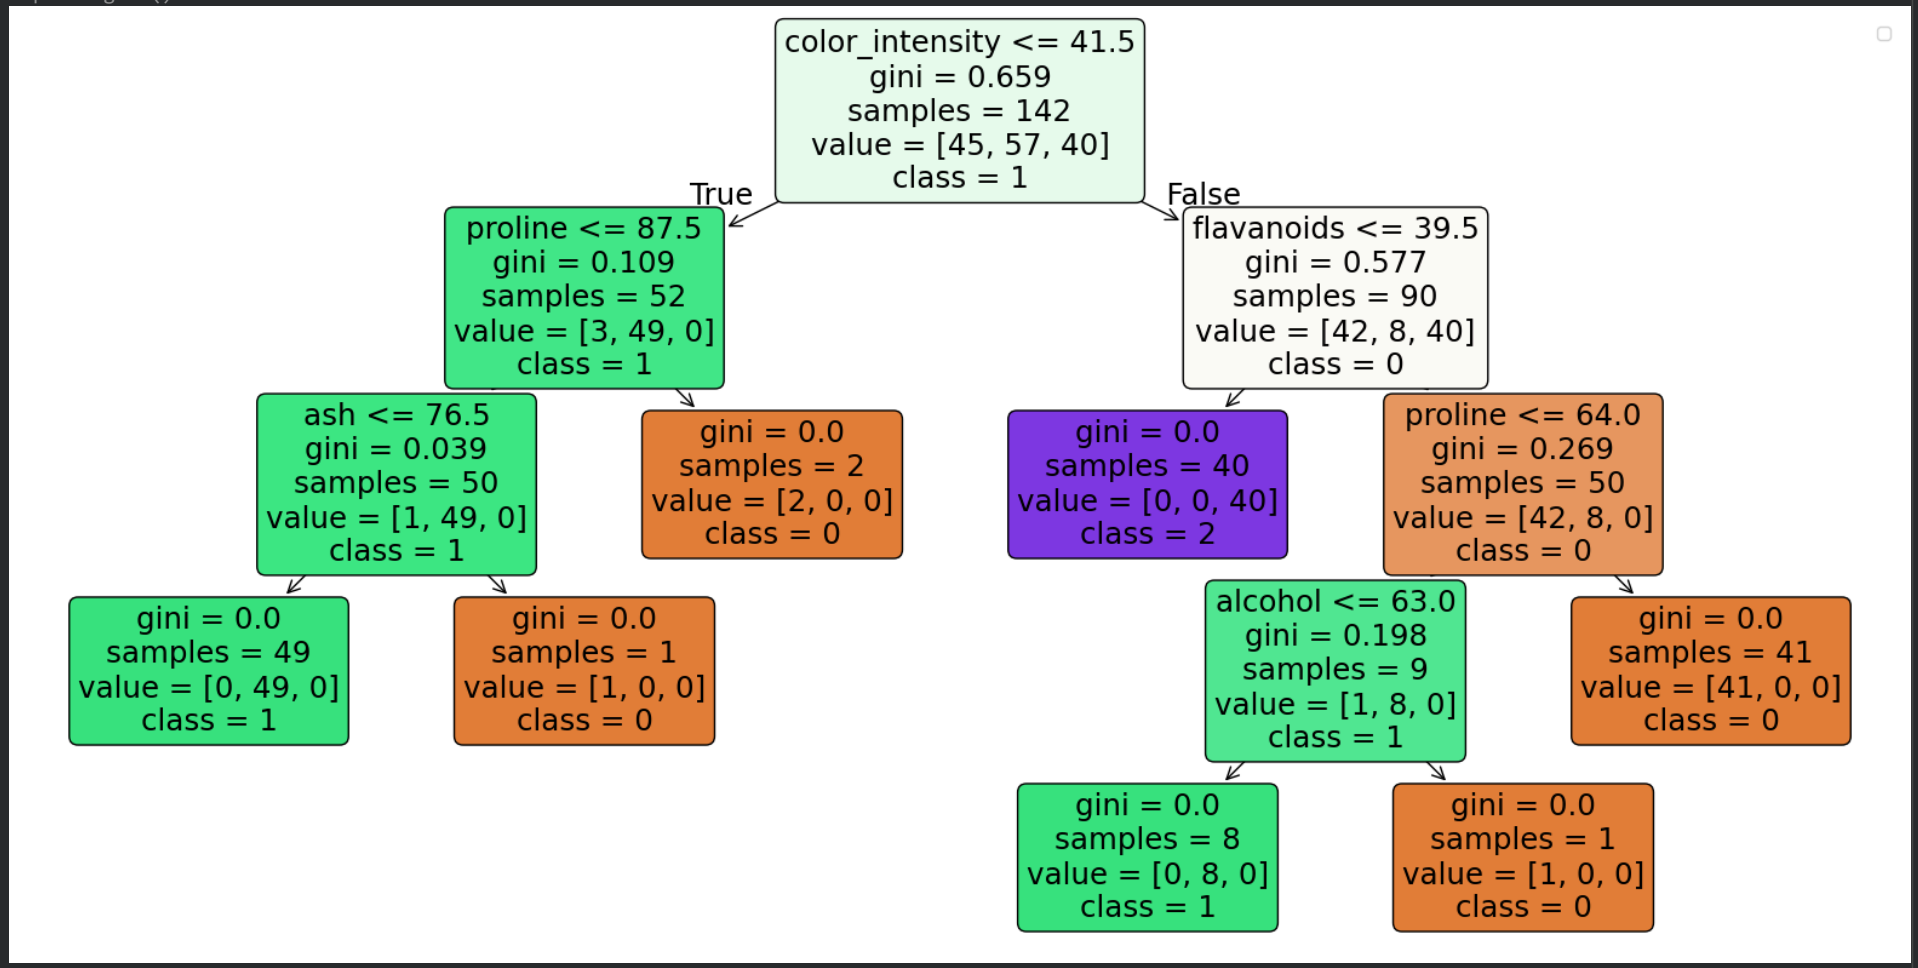

Relevancia de atributos:

```
importancias = pd.Series(clf.feature_importances_, index=x.columns).sort_values()

plt.figure(figsize=(8, 5))
importancias.plot(kind='barh')
plt.title('Relevancia de los atributos')
```

```
plt.xlabel('Importancia')
```

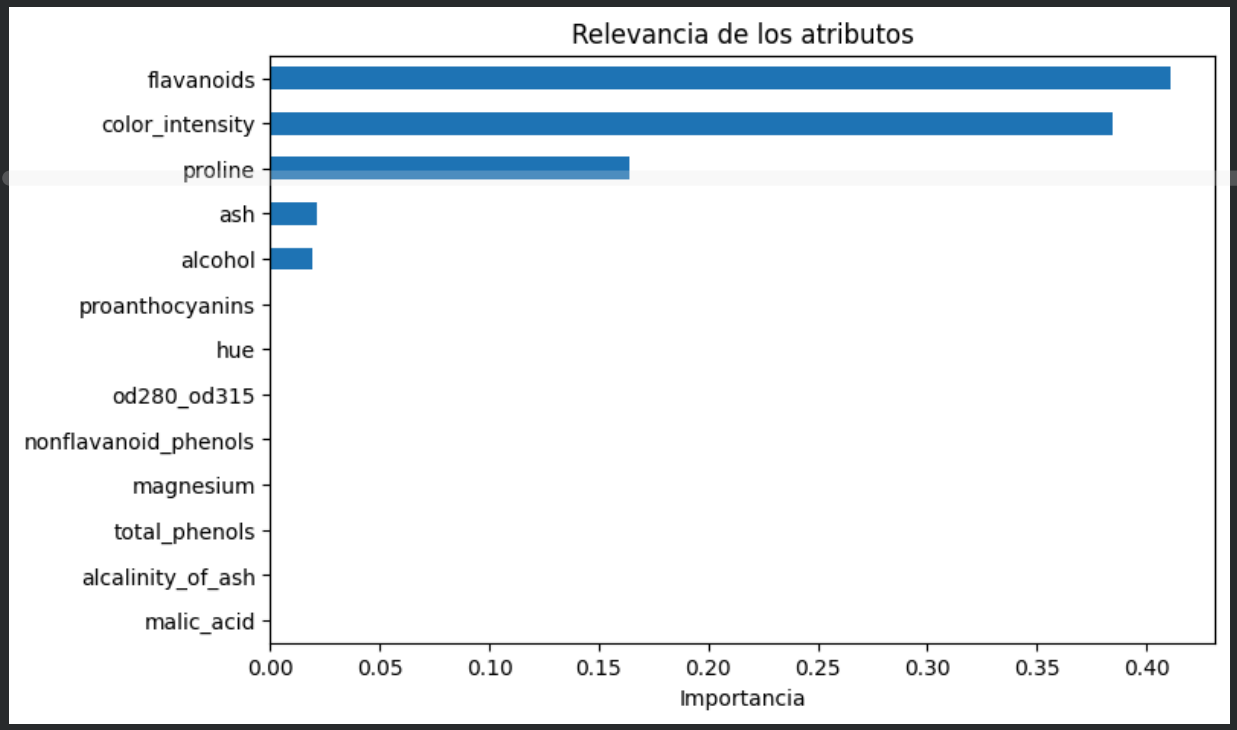

- Viendo el grafico, hay varios atributos como `magnesium`, `alcohol` o `total_phenols` entre otros que no tienen casi importancia.
- En contraste, los atributos que más importancia tienen son `flavanoids` y `color_intensity`.